Classificação de tópicos: case VDE

Fase 2: um sistema que decide sem modelo de linguagem

Leo Vitor

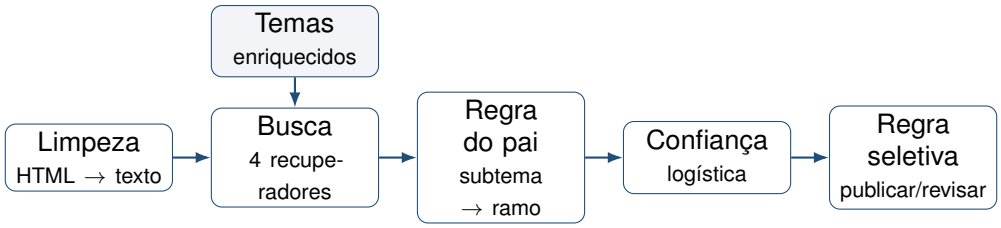
Sumário executivo

- **Resultado:** publiquei 115 das 659 questões (17,4%) e mandei 544 para revisão. Nas 559 questões fora da folha-verdade, a cobertura é 94/559 (0,17).
- **Previsão de precisão: 0,76 (0,53 a 0,90).** É a estimativa aninhada (13 acertos em 17), em que o limiar é escolhido sem ver o grupo medido. Na regra fixa, medida nos mesmos 100 rótulos, foram 19 em 20 (0,95): esse número é o teto otimista, não a previsão.
- **A meta de 95% não é demonstrável com 100 rótulos.** Pela cota unilateral de 95% (Clopper-Pearson), seriam precisas umas 60 publicações auditadas sem nenhum erro; o sistema publica 20 na folha-verdade.
- **Nenhum modelo de linguagem na decisão.** Um comando regenera a entrega em cerca de um minuto, sem rede. O único insumo gerado por LLM é o arquivo de temas enriquecidos, versionado por hash.

17,4%	0,76	0,74	R$ 0
COBERTURA (115/659)	PRECISÃO PREVISTA	RAMO CERTO NO TOP-1	CUSTO DE API POR QUESTÃO

a) O sistema

O sistema responde três perguntas, sempre na mesma ordem: qual é o tema mais provável, em que ramo da árvore ele está e se vale publicar. Nenhuma das três chama modelo de linguagem.



1. **Temas enriquecidos.** Os 351 temas ativos ganharam sinônimos, institutos e uma definição curta, gerados por LLM uma única vez, validados automaticamente (campos, leis e colisões) e congelados num arquivo versionado. É a peça que mais rendeu (tabela abaixo), e é exatamente o uso de LLM que o case permite.
2. **Busca com quatro recuperadores.** TF-IDF por palavra, TF-IDF por caractere, BM25 e a fusão deles (RRF). A fusão é a que ranqueia; os quatro juntos servem para medir consenso.
3. **Regra do pai.** Se o mais provável é um subtema, publico o tema pai. Pela régua, o pai vale para o subtema certo e para todos os irmãos, então a regra nunca transforma um acerto em erro. Na folha, ela eliminou os erros entre irmãos: nenhum dos erros restantes é desse tipo.
4. **Confiança.** Uma regressão logística sobre 13 sinais do topo do ranking (margens, consenso entre recuperadores, nível do tema, disciplina de origem, tamanho do tema na origem e score do primeiro), treinada fora da dobra nos 100 rótulos.
5. **Regra seletiva.** Publica só se pelo menos três dos quatro recuperadores concordarem e a confiança passar de 0,896. O resto vai para revisão, com a sugestão do sistema.

Texto usado para cada tema (92 questões com tema)	Ramo certo no top-1	Diferença
Caminho e título (base)	0,630	
Base e títulos dos filhos	0,630	0,000
Base e termos do dicionário jurídico	0,620	−0,011
Só sinônimos	0,609	−0,022
Enriquecido (sinônimos, institutos e definição)	**0,739**	**+0,109**

O critério de entrada foi escrito antes do teste (ganho de pelo menos 0,05). O intervalo pareado do ganho é de 0,033 a 0,196: positivo, mas não folgado. Nenhum campo isolado basta; o ganho vem da combinação.

O que testei e descartei. Cada ideia entrava só com ganho medido no ramo certo no top-1.

- **Embeddings densos** (multilingual-e5-large), mesmo com os temas enriquecidos: 0,53 a 0,68 sozinhos; a melhor fusão ganhou uma questão, com intervalo cruzando zero. Distinções jurídicas são lexicais (um número de lei, um termo técnico), e o embedding as aproxima.
- **Vizinhos entre questões (kNN):** só 41 dos 109 ramos aparecem na folha, então o teto é baixo (0,79 com acerto perfeito) e o resultado ficou em 0,43 a 0,48.
- **Reranker de candidatos** (16 sinais): empatou ou perdeu. **Cascata em dois estágios**: dá a mesma decisão da regra do pai. **Disciplina de origem como prior**: duas questões a mais em 92, dentro do ruído.
- **O sinal de lei citada**, que entrou e saiu. Tinha 1 caso positivo em 100 e dominava a confiança. Removê-lo custou 5 das 6 publicações de Legislação Especial e derrubou a precisão aninhada de 0,87 para 0,76. Preferi um número pior a um sistema apoiado num caso.

b) Os 100 rótulos

Como usei. Os 100 rótulos tiveram três papéis, sempre separados: escolher peças do sistema (com o critério escrito antes), treinar a confiança e medir a precisão. Para não medir no que treinei, usei 5 dobras repetidas 5 vezes, estratificadas por disciplina e com questões quase iguais sempre na mesma dobra (não houve nenhuma). O limiar de publicação é escolhido dentro de cada dobra e aplicado na parte que ficou de fora. Ao auditar esse protocolo, achei um vazamento: o limiar era escolhido com probabilidades que já tinham visto o grupo de teste. Corrigido, as publicações aninhadas caíram de 33 para 17. O número que entrego é o corrigido.

Leitura (pela régua do case)	Publicadas	Acertos	Precisão (IC 95% Wilson)
Regra fixa, in-sample (mesmos 100)	20	19	0,95 (0,76 a 0,99)
Aninhada, limiar escolhido fora do grupo	**17**	**13**	**0,76 (0,53 a 0,90)**
Publicando tudo	100	68	0,68

O que os rótulos mostraram sobre a convenção da equipe.

- **Gêmeos.** Oito temas aparecem duas vezes, com o mesmo título, em disciplinas diferentes. Nas 6 questões da folha com tema gêmeo, a equipe usou o de Legislação Especial em 5; na Q0324 marcou os dois (um como central, outro como extra). E não seguiu a disciplina de origem: a Q0091 veio como Direito Penal e foi para Lei de Execução Penal (Legislação Especial). Na fase 1, quando o gêmeo não batia com a disciplina de origem, eu mandava a questão para revisão; os rótulos mostram que essa regra teria barrado um acerto (Q0091). São só 6 casos.
- **Nível e extras.** A equipe rotula no tema em 53 das 92 questões e no subtema em 39, e usa extras em 39: questões multitemáticas são comuns, e os extras dão mais de um jeito de acertar pela régua.
- **Fora da árvore:** 8 das 100, sem nenhum traço comum que permita detectá-las.
- **A régua pesa.** A mesma predição acerta 0,95 in-sample pela régua do case, 0,90 se só o ramo contasse e 0,50 se fosse exigido o tema exato. O sistema acerta o ramo, não o subtema.

c) Diagnóstico

O que atrapalha nos dados e nos temas. Os gêmeos, que a régua não deixa trocar. As lixeiras, temas que concentram centenas de questões na origem. O assunto de origem, que também é uma lixeira ("Concurso de Crimes" rotula 43 questões de temas variados). A sobreposição entre a lei especial e o instituto correspondente do Código. E um erro de catálogo: pela Lei 14.197/2021, os temas 5148 e 5156 são capítulos do tema 5155. Corrigi isso no entregável, sem trocar IDs. É uma correção legal, não um ajuste de métrica: nenhuma publicação cai nesses temas, mas a mudança de texto deslocou 18 decisões, com 15 publicações perdidas, 3 ganhas e saldo de -12. A avaliação de precisão continua sendo feita contra a árvore original; por isso declaro o custo e levo a correção ao professor para confirmação.

Onde o sistema perde. Nas 92 questões com tema: 20 publicadas certas, 1 publicada errada, 48 em revisão com o ramo certo já em primeiro (18 passariam com um limiar mais baixo; 30 precisam de uma confiança melhor), 18 com o ramo certo entre o 2º e o 10º lugar e 5 fora do top-10. A busca não é mais o gargalo principal: a confiança é.

Que questões o sistema ainda erra, e o que resolveria cada uma.

Tipo de questão	O que acontece	O que resolveria
Lei de Execução Penal	vai para Teoria da Pena (3 casos); o texto fala de remição ou falta grave, sem citar a lei	descrição do tema 4703 com o vocabulário da execução
Juizado Especial Criminal	vai para procedimento ou ação penal (3 casos), apesar de citar a Lei 9.099	usar a lei citada como evidência, a testar com rótulos novos
Gabarito em subtema	erra o ramo em 36%, contra 19% quando o gabarito é tema	mais rótulos de subtema
Erro confiante	a Q0202 foi publicada errada com confiança 0,97: os quatro recuperadores leem o mesmo texto e erram juntos	um sinal que não venha da busca, validado em rótulos novos
Fora da árvore	8 casos sem traço comum	revisão humana; criar os temas que faltam

Legislação Especial concentra o problema: erra o ramo em 6 de 12 questões, contra 10% em Criminologia. A regra da lei citada não entrou na entrega porque foi desenhada depois de ver os erros e tem poucos casos; fica como o primeiro teste da próxima rodada.

d) Produção: 50 mil questões por semana

Custo e tempo. Classificar as 659 questões leva cerca de 40 segundos num núcleo; 50 mil levam perto de uma hora, sem GPU e sem API. O LLM só volta quando o catálogo muda, para enriquecer os temas novos ou alterados, uma vez por tema. O custo que não escala é a fila: com 17% de publicação, uns 41 mil itens por semana iriam para revisão. Por isso a fila deve ser ordenada pela confiança, com as questões mais perto do limiar primeiro, porque são as que mais mudam de decisão com um rótulo.

Como eu colocaria em produção. Com precisão estimada de 0,76, eu não deixaria o sistema publicar sozinho no começo: uma em cada quatro publicadas estaria errada, que é o problema que a plataforma quer resolver. Hoje ele serve como triagem: o ramo certo está em primeiro lugar em 74% das questões e entre os dez primeiros em 95%, então o professor confirma uma sugestão ou escolhe numa lista curta, em vez de procurar entre 375 temas. O caminho seria: (1) modo sombra, em que o sistema sugere e o professor decide; (2) publicação liberada por partes, só nos temas e faixas de confiança em que a amostra auditada passar de 95%; (3) auditoria separada das importações novas, porque o modelo publica um pouco mais nas 300 questões recentes (18%, 54 de 300) do que nas antigas fora da folha (15%, 40 de 259), e isso pode ser excesso de confiança.

Como a correção do professor vira dado de treino. Cada revisão gera uma linha: questão, tema sugerido, tema final e se a sugestão estava certa. Essa linha serve a quatro coisas:

1. é o rótulo "certo ou errado" que o modelo de confiança aprende, que é o gargalo atual;

2. amplia a folha-verdade, que recalibra o limiar e mede a precisão;
3. mostra quais temas acumulam correções, e esses são reenriquecidos;
4. com alguns milhares de linhas, permite treinar um classificador direto sobre o texto.

De quanto em quanto tempo o sistema se retreina.

Peça	Quando	Condição para entrar em produção
Modelo de confiança	toda semana, com as revisões novas	não piorar no protocolo aninhado
Limiar de publicação	a cada uns 100 rótulos novos	precisão aninhada de pelo menos 95%
Temas enriquecidos	quando o catálogo muda	passar no validador; hash novo
Classificador de texto	quando houver uns milhares de rótulos	superar a busca no aninhado

Os volumes (100 rótulos, alguns milhares) são estimativas minhas, a confirmar com o uso.

Como medir a qualidade. Toda semana: a precisão numa amostra de publicadas auditada pelo professor, a taxa de sugestões corrigidas na fila e os reportes de alunos por tema. Para afirmar 95% com segurança pela cota unilateral, a amostra auditada precisa ser de 60 publicações sem erro, não de poucas unidades.

O que eu faria com mais tempo. Em ordem de retorno: (1) rótulos priorizados, primeiro nas questões que citam lei, em Legislação Especial e perto do limiar; (2) a regra da lei citada, testada com rótulos novos; (3) o vocabulário da execução no tema 4703; (4) um sinal de confiança independente da busca, a validar com rótulos novos (o assunto de origem é um candidato, mas hoje é ruidoso); (5) exemplos por tema propostos por LLM e revisados, para cobrir os 68 ramos ausentes da folha.

e) Memo para o professor

Para você, especialista em Direito. Sem jargão de IA.

O que eu construí

- Um sistema que decide, para cada uma das 659 questões, se publica o tema ou manda para a sua revisão. Ele compara o texto da questão com a descrição dos temas e não consulta nenhum modelo de linguagem, como o ChatGPT, na hora de decidir. Publiquei 115 (17%) e mandei 544 para você.
- Espero que umas 3 de cada 4 publicadas estejam certas. Não consigo prometer os 95% pedidos: com 100 questões rotuladas, não há como provar isso.
- Na prática, hoje o sistema é mais útil para sugerir o tema do que para publicar sozinho: ele coloca o tema certo entre as dez primeiras opções em 95% das questões.

O que encontrei

- O sistema acerta o assunto geral em 3 de cada 4 questões; quando erra, em geral confunde temas vizinhos. Ele publica no tema principal, não no subtema, porque a régua aceita isso e é mais seguro.
- A maior dificuldade é Legislação Especial: metade das questões vai para o tema correspondente do Código. Questões de execução da pena vão para Teoria da Pena, e questões de Juizado Especial vão para procedimento ou ação penal.
- Quando a questão cita uma lei especial, isso costuma ser uma pista, mas ainda não usei como regra: são poucos casos e a ideia veio depois de eu ver os erros.
- Nos temas com nome repetido em duas disciplinas, a sua equipe usou quase sempre o de Legislação Especial (5 de 6), e não a disciplina de onde a questão veio.

O que recomendo mudar nos temas

- Dar nomes diferentes aos 8 pares de temas repetidos (por exemplo, citar a disciplina no título): 4684/6716, 5063/5466, 4688/6717, 4702/6723, 4704/6724, 4703/6734, 4705/6725 e 4708/6728.
- Deixar mais clara a fronteira entre Lei de Execução Penal e Teoria da Pena, e entre Juizado Especial Criminal e Procedimento Sumaríssimo.
- Confirmar a correção que eu já fiz em “Instituições Democráticas” (5148) e “Funcionamento dos Serviços Essenciais” (5156): pela Lei 14.197/2021, são capítulos de “Estado Democrático de Direito” (5155), não temas irmãos dele.
- Rever os temas que hoje acumulam centenas de questões sem relação com eles.

O que preciso de você

- Revisar primeiro as questões que eu ordenar na fila: as mais perto da decisão. Cada correção sua ensina o sistema e é o que permite, com o tempo, publicar mais com segurança.
- Rotular de 200 a 300 questões, começando pelas que citam lei e pelas de Legislação Especial. No ritmo atual, isso dá umas 35 a 50 publicadas para calibrar; não prova 95%. Para provar, seria preciso auditar 60 publicadas sem erro.
- Confirmar qual dos dois nomes é o oficial em cada par de temas repetidos.