Classificação de tópicos: case VDE

Fase 2: um sistema que decide sem modelo de linguagem

Leo Vitor

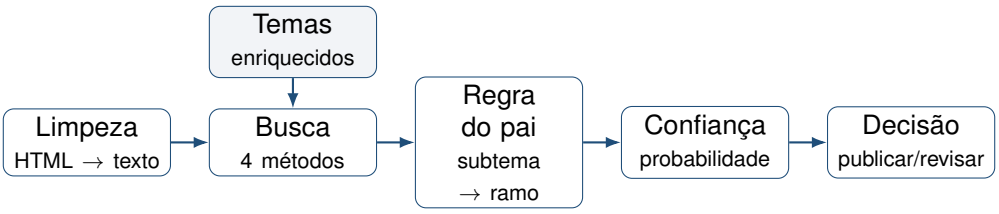
Sumário executivo

- **Resultado:** publiquei 115 das 659 questões (17,4%) e mandei 544 para a revisão do professor. Nas 559 questões fora da folha-verdade, publiquei 94 (0,17).
- **Previsão de precisão: 0,76, com faixa de 0,53 a 0,90.** É a medida mais honesta que tenho: 13 acertos em 17 publicações, numa avaliação em que a regra nunca viu as questões usadas para medi-la. Quando meço a regra nas mesmas questões que a ajustaram, ela acerta 19 de 20 (0,95), mas esse número é otimista e não é a minha previsão.
- **A meta de 95% não é demonstrável com 100 rótulos.** Mesmo sem nenhum erro, eu precisaria conferir umas 60 publicações para provar 95%; na folha-verdade o sistema publica 20.
- **Nenhum modelo de linguagem na hora de decidir.** Um comando refaz toda a entrega em cerca de um minuto, sem internet. O único material produzido por um LLM é a descrição ampliada dos temas, gerada uma vez e guardada no repositório.

17,4%	0,76	0,74	R$ 0
COBERTURA (115/659)	PRECISÃO PREVISTA	ASSUNTO CERTO EM 1º	CUSTO DE API

a) O sistema

O sistema responde a três perguntas, sempre na mesma ordem: qual é o tema mais provável, a que assunto geral ele pertence e se vale publicar. Chamo de **ramo** o tema de primeiro nível da árvore (por exemplo, “Teoria da Pena”); os subtemas ficam abaixo dele. Nenhuma das três perguntas consulta um modelo de linguagem.



1. **Temas enriquecidos.** O catálogo traz, para cada tema, só o nome e o caminho na árvore, o que é pouco para comparar com o texto de uma questão. Um LLM escreveu, uma única vez, uma descrição ampliada dos 351 temas ativos: sinônimos, institutos jurídicos e uma definição curta. Um programa conferiu automaticamente campos, leis citadas e repetições entre pai e filho, e o arquivo ficou congelado no repositório. Foi a peça que mais rendeu (tabela abaixo), e é exatamente o uso de LLM que o case permite.
2. **Busca com quatro métodos.** Cada método ordena os temas do mais ao menos parecido com a questão. Dois contam palavras em comum, valorizando as raras (TF-IDF por palavra e o BM25, usado em buscadores); um compara pedaços de palavras, o que tolera plural e conjugação (TF-IDF por caractere); o quarto junta os três rankings num só (fusão RRF). A fusão escolhe o tema; os quatro juntos dizem se há **consenso**.
3. **Regra do pai.** Se o tema mais provável é um subtema, publico o ramo acima dele. Pela régua do case, publicar no pai conta como acerto para o subtema certo e para todos os seus irmãos, então essa regra nunca transforma um acerto em erro. Na folha-verdade, ela eliminou os erros entre subtemas vizinhos.

4. **Confiança.** Para cada questão, calculo 13 **sinais**: números que ajudam a prever se a busca acertou. Por exemplo, a distância entre o primeiro e o segundo tema do ranking, quantos métodos concordam, o nível do tema na árvore e se a disciplina de origem bate com a do tema. Uma regressão logística, um modelo estatístico simples, combina os sinais numa probabilidade de acerto. Ela aprendeu com os 100 rótulos, sempre medida em questões que não viu.
5. **Decisão.** Publico só quando pelo menos três dos quatro métodos concordam e a probabilidade de acerto passa de 0,896 (o **limiar**). O resto vai para revisão, com a sugestão do sistema.

Descrição usada para cada tema (92 questões com tema)	Ramo certo em 1º	Diferença
Caminho e título (o catálogo original)	0,630	
Catálogo e títulos dos subtemas	0,630	0,000
Catálogo e termos de um dicionário jurídico	0,620	−0,011
Só sinônimos	0,609	−0,022
Descrição enriquecida (sinônimos, institutos e definição)	**0,739**	**+0,109**

Escrevi o critério antes do teste: só entraria com ganho de pelo menos 0,05. O ganho foi de 0,109, com faixa provável de 0,033 a 0,196 comparando questão a questão: positivo, mas sem folga. Nenhum campo sozinho resolve; o ganho vem da combinação.

O que testei e descartei. Cada ideia só entrava se melhorasse o acerto do ramo em primeiro.

- **Embeddings**, que representam o texto como uma lista de números que captura o sentido (testei o multilingual-e5-large, inclusive com os temas enriquecidos): 0,53 a 0,68 sozinhos, e a melhor combinação com a busca ganhou uma única questão. O que separa temas jurídicos vizinhos é a palavra exata (um número de lei, um termo técnico), e o embedding aproxima justamente o que eu preciso separar.
- **Vizinhos entre questões (kNN)**, que dá a uma questão o tema das questões rotuladas mais parecidas: só 41 dos 109 ramos aparecem na folha-verdade, então nem um acerto perfeito passaria de 0,79. Ficou em 0,43 a 0,48.
- **Um segundo modelo para reordenar os candidatos** (16 sinais por par questão e tema): empatou ou perdeu. **Decidir primeiro a disciplina e depois o tema**: deu a mesma decisão da regra do pai. **Dar peso à disciplina de origem**: duas questões a mais em 92, dentro do acaso.
- **Um sinal de lei citada**, que entrou e saiu. Tinha um único caso positivo nas 100 e dominava a probabilidade. Removê-lo custou 5 das 6 publicações de Legislação Especial e derrubou a precisão honesta de 0,87 para 0,76. Preferi um número pior a um sistema apoiado num caso só.

b) Os 100 rótulos

Como usei. A folha-verdade (as 100 questões rotuladas pela equipe) teve três papéis, sempre separados: escolher as peças do sistema, com o critério escrito antes; treinar o modelo de confiança; e medir a precisão. O cuidado central foi não medir nas mesmas questões em que ajustei. Medir assim é como corrigir a própria prova: o resultado sai bom demais. Os estatísticos chamam isso de medida **in-sample** (“dentro da amostra”).

Para evitar isso, usei **validação cruzada aninhada**. Divido as 100 questões em 5 partes; ajusto o modelo e o limiar em 4 delas e meço na quinta, que ficou de fora; repito trocando a parte de fora e, depois, refaço tudo com 5 sorteios diferentes. Questões quase iguais ficariam sempre na mesma parte (não houve nenhuma). Ao auditar esse processo, achei um **vazamento**: o limiar era escolhido com probabilidades que já tinham visto a parte de teste. Corrigido, as publicações nessa medida caíram de 33 para 17. O número que entrego é o corrigido.

Como a precisão foi medida (régua do case)	Publicadas	Acertos	Precisão (faixa de 95%)
Nas mesmas 100 que ajustaram a regra (in-sample)	20	19	0,95 (0,76 a 0,99)
Aninhada: regra ajustada sem ver o grupo medido	**17**	**13**	**0,76 (0,53 a 0,90)**
Publicando todas as 100	100	68	0,68

A faixa (intervalo de confiança de Wilson) mostra os valores compatíveis com o que medi. Uma ressalva: a validação aninhada protege a escolha do limiar, mas os sinais e a forma da regra foram escolhidos olhando os mesmos 100 rótulos. Por isso o 0,76 ainda pode ser otimista, e não tenho como medir quanto.

O que os rótulos mostraram sobre a convenção da equipe.

- **Temas gêmeos.** Oito temas aparecem duas vezes, com o mesmo título, em disciplinas diferentes (por exemplo, Lei de Execução Penal em Legislação Especial e em Processo Penal). Nas 6 questões da folha com tema gêmeo, a equipe usou o de Legislação Especial em 5; na Q0324 marcou os dois. E não seguiu a disciplina informada na origem: a Q0091 veio como Direito Penal e foi para Lei de Execução Penal, em Legislação Especial. Na fase 1, eu mandava para revisão o gêmeo que não batia com a disciplina de origem; essa regra teria barrado um acerto. São só 6 casos.
- **Tema ou subtema.** A equipe rotula no tema em 53 das 92 questões e no subtema em 39, e indica temas extras em 39: questões que cobram mais de um assunto são comuns, e os extras dão mais de um jeito de acertar.
- **Fora da árvore:** 8 das 100 não têm tema adequado, e não encontrei nada em comum entre elas que permitisse detectá-las.
- **A régua pesa muito.** As mesmas 20 publicações acertam 0,95 pela régua do case, 0,90 se só o ramo contasse e 0,50 se fosse exigido o tema exato. O sistema acerta o assunto geral, não o detalhe.

c) Diagnóstico

O que atrapalha nos dados e nos temas. Primeiro, as **lixeiras**: temas genéricos que, na classificação automática antiga, receberam centenas de questões que não eram deles. Quanto mais cheio um tema está na origem, menos esse histórico informa. O próprio assunto de origem também virou lixeira: "Concurso de Crimes" rotula 43 questões de temas variados. Segundo, os gêmeos, que a régua não deixa trocar. Terceiro, a sobreposição entre uma lei especial e o instituto correspondente do Código. Por último, um erro de catálogo: pela Lei 14.197/2021, os temas 5148 e 5156 são capítulos do tema 5155, não irmãos dele. Corrigi isso no entregável, sem trocar IDs. Nenhuma publicação cai nesses temas, mas a mudança de texto mexeu em 18 decisões: 15 publicações perdidas e 3 ganhas. Como a avaliação usa a árvore original, declaro o custo e levo a correção ao professor.

Onde o sistema perde. Nas 92 questões com tema: 20 publicadas certas e 1 publicada errada; 48 foram para revisão com o ramo certo já em primeiro lugar (18 passariam com um limiar mais baixo, 30 precisariam de uma confiança melhor); 18 tinham o ramo certo entre o 2º e o 10º lugar; e 5 nem apareciam entre os dez primeiros. A busca já não é o gargalo principal: o que falta é o sistema saber quando está certo.

Que questões o sistema ainda erra, e o que resolveria cada uma.

Tipo de questão	O que acontece	O que resolveria
Lei de Execução Penal	vai para Teoria da Pena (3 casos); o texto fala de remição ou falta grave sem citar a lei	descrever o tema 4703 com o vocabulário da execução
Juizado Especial Criminal	vai para procedimento ou ação penal (3 casos), mesmo citando a Lei 9.099	usar a lei citada como evidência, testada com rótulos novos
Gabarito em subtema	erra o ramo em 36%, contra 19% quando o gabarito é tema	mais rótulos de subtema
Erro confiante	a Q0202 foi publicada errada com 0,97 de confiança: os quatro métodos leem o mesmo texto e erram juntos	um sinal que não venha da busca, testado com rótulos novos
Fora da árvore	8 casos sem nada em comum	revisão humana; criar os temas que faltam

Legislação Especial concentra o problema: erra o ramo em 6 de 12 questões, contra 10% em Criminologia. Testei depois usar a lei citada como regra, mas a ideia veio de olhar esses erros e tem poucos casos; ficou fora da entrega e é o primeiro teste da próxima rodada.

d) Produção: 50 mil questões por semana

Custo e tempo. Classificar as 659 questões leva cerca de 40 segundos num processador comum; 50 mil levariam perto de uma hora, sem placa de vídeo e sem pagar API. O LLM só volta quando o catálogo muda, para descrever os temas novos ou alterados, uma vez por tema. O custo que não escala é a fila: com 17% de publicação, uns 41 mil itens por semana iriam para revisão. Por isso a fila deve ser ordenada pela confiança, com as questões mais perto do limiar primeiro: são as que mais mudam de decisão com um rótulo novo.

Como eu colocaria em produção. Com precisão estimada de 0,76, eu não deixaria o sistema publicar sozinho no começo: uma em cada quatro publicadas estaria errada, que é o problema que a plataforma quer resolver. Hoje ele serve como triagem: o ramo certo está em primeiro lugar em 74% das questões e entre os dez primeiros em 95%, então o professor confirma uma sugestão ou escolhe numa lista curta, em vez de procurar entre 375 temas. O caminho seria: (1) um período em que o sistema só sugere e o professor decide; (2) publicação liberada por partes, só nos temas e faixas de confiança em que a amostra auditada passar de 95%; (3) auditoria separada das importações novas, porque o sistema publica um pouco mais nas 300 questões recentes (18%, 54 de 300) do que nas antigas (15%, 40 de 259), o que pode ser excesso de confiança.

Como a correção do professor vira dado de treino. Cada revisão gera uma linha: questão, tema sugerido, tema final e se a sugestão estava certa. Essa linha serve a quatro coisas:

1. é o rótulo de “acertou ou errou” que o modelo de confiança aprende, e esse é o gargalo atual;
2. amplia a folha-verdade, que recalibra o limiar e mede a precisão;
3. mostra quais temas acumulam correções, e esses ganham uma descrição melhor;
4. com alguns milhares de linhas, permite treinar um classificador direto sobre o texto.

De quanto em quanto tempo o sistema se retreina.

Peça	Quando	Condição para entrar em produção
Modelo de confiança	toda semana, com as revisões novas	não piorar na validação aninhada
Limiar de publicação	a cada uns 100 rótulos novos	precisão aninhada de pelo menos 95%
Descrição dos temas	quando o catálogo muda	passar na conferência automática
Classificador de texto	quando houver uns milhares de rótulos	superar a busca na validação

Os volumes (100 rótulos, alguns milhares) são estimativas minhas, a confirmar com o uso.

Como medir a qualidade. Toda semana, três números: a precisão numa amostra de publicadas conferida pelo professor, a fração de sugestões corrigidas na fila e os reportes de alunos por tema. A amostra precisa ser grande. Com zero erros em n questões conferidas, só dá para garantir que o erro fica abaixo de cerca de $3/n$; para garantir 95% de precisão, são precisas umas 60 publicações conferidas sem nenhum erro. Com 20, mesmo sem erro, só se garante 86%.

O que eu faria com mais tempo. Em ordem de retorno: (1) mais rótulos, começando pelas questões que citam lei, pelas de Legislação Especial e pelas mais perto do limiar; (2) a regra da lei citada, testada nesses rótulos novos; (3) o vocabulário da execução penal no tema 4703; (4) um sinal de confiança que não venha da busca, já que hoje todos os sinais nascem da mesma comparação de texto e erram juntos; (5) exemplos de questões por tema, propostos por um LLM e revisados por um professor, para cobrir os 68 ramos que não aparecem na folha-verdade.

Uma conclusão atravessa o trabalho: o gargalo é o número de rótulos, não o modelo. Uma semana com 100 rótulos novos, bem escolhidos, renderia mais do que qualquer algoritmo novo.

e) Memo para o professor

Para você, especialista em Direito. Sem jargão de IA.

O que eu construí

- Um sistema que decide, para cada uma das 659 questões, se publica o tema ou manda para a sua revisão. Ele compara o texto da questão com a descrição dos temas e não consulta nenhum modelo de linguagem, como o ChatGPT, na hora de decidir. Publiquei 115 (17%) e mandei 544 para você.
- Espero que umas 3 de cada 4 publicadas estejam certas. Não consigo prometer os 95% pedidos: com 100 questões rotuladas, não há como provar isso.
- Na prática, hoje o sistema é mais útil para sugerir o tema do que para publicar sozinho: o assunto certo aparece entre as dez primeiras opções em 95% das questões.

O que encontrei

- O sistema coloca o assunto certo em primeiro lugar em cerca de 74% das questões; quando erra, em geral confunde temas vizinhos. Ele publica no tema principal, não no subtema, porque a régua aceita isso e é mais seguro.
- A maior dificuldade é Legislação Especial: metade das questões vai para o tema correspondente do Código. Questões de execução da pena vão para Teoria da Pena, e questões de Juizado Especial vão para procedimento ou ação penal.
- Quando a questão cita uma lei especial, isso costuma ser uma pista, mas ainda não usei como regra: são poucos casos e a ideia veio depois de eu ver os erros.
- Nos temas com nome repetido em duas disciplinas, a sua equipe usou quase sempre o de Legislação Especial (5 de 6), e não a disciplina de onde a questão veio.

O que recomendo mudar nos temas

- Dar nomes diferentes aos 8 pares de temas repetidos (por exemplo, citar a disciplina no título): 4684/6716, 5063/5466, 4688/6717, 4702/6723, 4704/6724, 4703/6734, 4705/6725 e 4708/6728.
- Deixar mais clara a fronteira entre Lei de Execução Penal e Teoria da Pena, e entre Juizado Especial Criminal e Procedimento Sumaríssimo.
- Confirmar a correção que fiz em “Instituições Democráticas” (5148) e “Funcionamento dos Serviços Essenciais” (5156): pela Lei 14.197/2021, são capítulos de “Estado Democrático de Direito” (5155), não temas irmãos dele.
- Rever os temas genéricos que hoje acumulam centenas de questões sem relação com eles.

O que preciso de você

- Revisar primeiro as questões que eu ordenar na fila: as mais perto da decisão. Cada correção sua ensina o sistema e é o que permite, com o tempo, publicar mais com segurança.
- Rotular de 200 a 300 questões, começando pelas que citam lei e pelas de Legislação Especial. É isso que permite, com o tempo, provar se o sistema chega a 95%.
- Confirmar qual dos dois nomes é o oficial em cada par de temas repetidos.