Classificação de tópicos: case VDE

Fase 2 — decidir sem LLM e provar o que 100 rótulos permitem

Autor: Léo Vitor

SUMÁRIO EXECUTIVO

- **Resultado:** publiquei 115 das 659 questões (17,4%), mandei 544 para revisão e nenhuma para *fora*.
- **Qualidade:** 19 acertos em 20 publicadas (0,95) na regra fixa; 13 em 17 (0,76) quando o limiar é escolhido fora do grupo medido. A previsão é 0,91 [0,76–0,99].
- **A meta de 95% não é certificável com 100 rótulos.** O primeiro nível que a amostra prova é 12% de erro (32 publicadas, 31 acertos); no protocolo honesto, 80%.
- **Nenhuma chamada de modelo na decisão:** o pipeline roda em menos de um minuto, sem rede, e o único insumo novo é um arquivo de 351 temas enriquecidos, versionado por hash.

17,4%	0,91	0,74	R$ 0
COBERTURA (115/659)	PRECISÃO PREVISTA	RAMO@1 (PISO: 0,64)	CUSTO DE INFERÊNCIA

A Fase 1 respondia com modelos de linguagem e media concordância com outro modelo. A Fase 2 faz a pergunta oposta: até onde vai um sistema determinístico, auditável e barato? A resposta é que ele chega a 0,95 de precisão publicando 17% das questões — e que essa precisão não pode ser *provada* com a amostra disponível. O relatório separa o que foi medido do que foi estimado em cada número.

A) COMO EU PENSEI

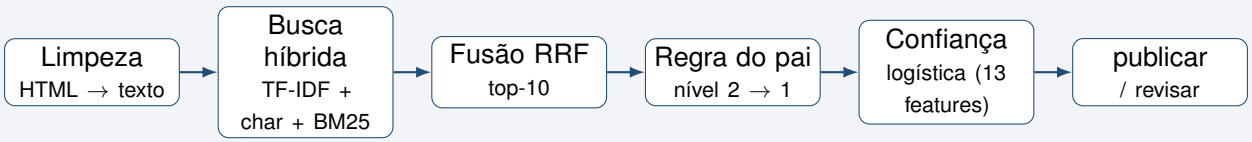
Comecei congelando a Fase 1 (tag `v1-fase1`) e tratando a Fase 2 como um experimento independente. A decisão é sempre a mesma pergunta de três partes: qual é o tema mais provável (busca lexical), qual é o ramo dessa predição (regra do pai) e vale publicar (confiança logística + regra seletiva). Nada disso chama modelo em tempo de execução.

O primeiro diagnóstico mudou o alvo. Como a regra do pai promove todo subtema ao tema de nível 1, *todas* as 100 predições saem no nível do ramo. A métrica que importa não é acertar o subtema: é acertar o **ramo** — e o teto de ramo no top-10 era 0,935 contra 0,641 no top-1. A pergunta virou: dá para subir o ramo@1 sem trocar a arquitetura?

Testei primeiro o que era grátis. Anexar os títulos dos filhos ao tema e aplicar o dicionário jurídico ao lado do tema não moveram nada: 0,63–0,64 nas duas variantes, o mesmo patamar da base. A leitura é que o caminho hierárquico já carrega o vocabulário dos filhos, e que o dicionário é um mapa questão→termo, não tema→termo.

Aí entrou o enriquecimento: 351 temas com sinônimos, institutos e uma definição curta, gerados offline e congelados num JSONL. O critério foi escrito antes de olhar o resultado: entrar só se `ramo@1` subisse $\geq +0{,}05$ sobre o melhor piso e a precisão não caísse na cobertura fixa de 20%. Subiu para **0,739** (+0,109) e a precisão a 20% de cobertura foi de 0,61 para 0,72. Entrou. A ablação mostrou por que: nenhum campo sozinho basta (sinônimos isolados ficam *abaixo* da base) nem é individualmente necessário (toda remoção fica no ruído); o ganho está na combinação — e somar o dicionário ao texto enriquecido chega a atrapalhar.

PIPELINE DA FASE 2 (SEM LLM NA DECISÃO)



O texto de cada tema é enriquecido (sinônimos + institutos + definição). A confiança só publica com consenso entre os quatro recuperadores e limiar escolhido fora da dobra.

Texto do tema	ramo@1	Δ vs. base
base (caminho + título)	0,630	—
+ títulos dos filhos	0,630	0,000
+ termos do dicionário	0,620	$-0{,}011$
só sinônimos, sem institutos nem texto	0,609	$-0{,}022$
enriquecido (sinônimos + institutos + texto)	**0,739**	$\mathbf{+0{,}109}$

Nota: 92 questões com tema; recuperador `rrf_all`. Os pisos gratuitos empatam com a base, e o artefato só vence quando os três campos entram juntos. Delta pareado com IC bootstrap de 95%: $[0{,}033;\ 0{,}196]$ — positivo, mas não folgado.

Também tentei o que parecia natural e não funcionou. Reranker de candidatos empata ou perde. Embeddings densos (`multilingual-e5-large`) melhoram o recall no top-10 e pioram o top-1, que é onde a decisão vive. k-NN entre questões também perde. A cascata de ramo em dois estágios — decidir o ramo, depois o subtema — não muda nada: agregar os filhos por máximo é exatamente a mesma decisão que promover o top-1, e publicar o subtema nunca salva um ramo errado (0 casos em 92). A disciplina de origem como prior dá +0,033, dentro do ruído (aninhado 0,761 contra 0,739); registrei e não adotei.

Por fim, auditei a própria avaliação e achei um vazamento: o limiar aninhado era escolhido com probabilidades que já tinham visto o grupo de teste. Corrigido, a cobertura a 95% caiu de 33 para 17 publicadas. O número que entrego é o corrigido.

B) DIAGNÓSTICO

A régua faz metade do trabalho. Na leitura literal do case (aceita tema, extra, pai ou filho) a regra final acerta 0,95; no tema exato, 0,50; no mesmo ramo, 0,90. Publicar o pai é ótimo para esta régua e não é trapaça — é o contrato —, mas quem julgar pelo tema exato vê um sistema diferente. O relatório mostra as três leituras para que ninguém precise descobrir isso sozinho.

Legislação Especial perdeu o que dependia do `lei_match`. Eram 6 publicações; 5 (Terrorismo, Organizações Criminosas, Desarmamento, Abuso de Autoridade, Tortura) sumiram com a remoção da feature. Na folha o estrato voltou a 0 (6 revisadas com top-1 certo) e nas 659 resta 1. O enriquecimento ainda põe o ramo certo no top-1, mas a publicação estava apoiada numa feature singleton. Criminologia mantém 6.

O custo do ganho é instabilidade. Trocar o texto do tema mudou 266 dos 659 temas (40,4%). E a medida mais limpa veio de uma correção de catálogo em três nós, que mudou 18 decisões sem mudar nenhum tema previsto entre as 15 publicações perdidas: a instabilidade mora na camada de decisão, não na busca. O sistema opera com margens pequenas, e isso não invalida a precisão medida, mas impede tratá-la como garantia.

Onde o erro mora. Das 100 questões, 68 acertam pela régua literal quando se publica tudo. O erro restante se divide entre 8 questões fora da taxonomia — que o sistema não marca como *fora*, porque não há sinal discriminante em 8 exemplos — e confusões entre ramos vizinhos. Marcar *fora* seria chute; *revisar* é a resposta conservadora e não afeta a precisão das publicadas.

O gargalo é misto: 30 de confiança, 18 de ranking e 5 de recall. Separando as 92 válidas em categorias exclusivas: 20 publicadas certas, 1 errada, **48 revisadas com o ramo certo já no top-1**

(18 passariam no limiar mais baixo do platô; 30 precisam de modelo), 18 com o ramo certo entre o 2º e o 10º e 5 fora do top-10. O top-10 cobre 94,6%, mas a busca ainda custa 5 casos, o ranking 18 e a confiança 30. O único erro publicado (Q0202) tinha o ramo certo em 10º e confiança 0,970 — excesso de confiança, não falta de informação.

Uma correção de catálogo, feita com a lei na mão. Conferi a Lei 14.197/2021: "Instituições Democráticas" é o Capítulo II do Título XII, e "Funcionamento dos Serviços Essenciais" é o Capítulo IV (art. 359-R, sabotagem) — não os arts. 265–266. Reparentei os dois sob "Estado Democrático de Direito" (o Título) e reescrevi o objeto de 5156. Não houve fusão de IDs, e o efeito está medido: 8 temas e 18 decisões.

A auditoria da camada de decisão foi refeita depois disso, com seis verificações:

Item	O que foi medido	Resultado
Métrica	leitura literal, estrita e frouxa da mesma predição	0,95 / 0,50 / 0,90
Validação	limiar escolhido fora do grupo medido (nested)	33 $\rightarrow$ 17 (havia vazamento)
Regras	logística $\times$ regras manuais de margem	33/30 contra 0 publicadas
Certificação	cota de Clopper-Pearson para o erro	95% e 90% impossíveis; 12% $\rightarrow$ 32/31
Conformidade	conjunto conformal + ancestral comum	$k = 59$ para 95% $\Rightarrow$ 0 publicações
Operação	origem das 115 publicações	61 antigas, 54 novas, 1 em Leg. Especial

Conjunto	Publicadas	Literal	Estrita
Regra final (consenso $\geq 0{,}75$ e $p \geq 0{,}896$)	20	**0,950**	0,500
Consenso $\geq 0{,}75$, sem limiar	83	0,723	0,458
Publicando tudo	100	0,680	0,430
Fora da folha-verdade (559): 94 publicadas = 0,17			
Antigas (259)	40	0,15	
Novas (300)	54	0,18	

In-sample com p_{oof} (20); o CSV usa p_{all} e publica 21 na folha (Q0049 entra, Q0202 erra): 21 + 94 = 115.

C) PRODUÇÃO (50 MIL QUESTÕES POR SEMANA)

O que escala e o que não escala. O pipeline é vetorizado: indexar os 371 temas leva menos de um segundo, e classificar 659 questões leva cerca de 40 segundos em um núcleo. Cinquenta mil questões por semana cabem em uma máquina modesta, sem GPU e sem API — o custo marginal é zero. O que não escala é a fila: publicar 17% significa mandar 83% para revisão humana, ou seja, 41 mil questões por semana. Esse é o gargalo real, não o compute.

Como eu atacaria a fila. Primeiro, usar a confiança como ordenação: as revisões mais próximas do limiar são as que mais mudam de resposta e devem ser vistas antes. A curva precisão $\times$ cobertura é plana entre 17% e 37% de cobertura (0,95 a 0,97): o limiar conservador custa 17 publicações sem ganho mensurável, mas movê-lo agora seria escolhê-lo no conjunto que mede — fica para a próxima rodada, com a regra pré-registrada. Segundo, acumular rótulos de professor e trocar a logística por um modelo calibrado — com 100 rótulos não dá; com algumas centenas, a cobertura a 95% cresce. Terceiro, atacar o ramo, que é o gargalo estrutural: o teto do ramo no top-10 é 0,946, então nenhuma regra de decisão conserta um top-1 que já nasceu errado.

Manutenção do artefato. O enriquecimento é um arquivo por taxonomia. Quando um tema muda, o objeto correspondente muda com ele; o validador (contrato de campos, whitelist de leis, blacklist, colisões pai/filho) roda em segundos e barra o resto. O hash do arquivo entra no manifesto de auditoria, então qualquer número do relatório é reproduzível a partir do commit.

Custo de medir. A meta de 95% não é certificável com 100 rótulos: para 0 erros, seriam necessárias 60 publicadas perfeitas. O caminho barato é rotular os casos de *desacordo* — onde a regra e o modelo discordam —, que é onde está a informação; o caminho caro é uma amostra aleatória de centenas. Enquanto isso, o honesto é publicar pouco e dizer o intervalo.

Limitações que eu levaria para a produção. (i) A amostra é de 100 questões e 1 acerto vale 1 ponto percentual; (ii) os gêmeos de catálogo continuam sem convenção; (iii) 8 exemplos de *fora* não sustentam um classificador de fora; (iv) o enriquecimento foi escrito por um modelo e revisado por mim — não é conhecimento de especialista; (v) a instabilidade medida — 18 decisões movidas por uma correção de três nós — significa que a fila muda de composição a cada mudança de vocabulário.

O que eu faria com mais tempo. Quatro coisas, em ordem de retorno: rótulos de professor para 200–300 questões (é o único caminho para certificar 95%); uma convenção para os gêmeos e para as duplicatas de nível 1; um classificador de disciplina treinado em texto, para substituir o metadado de origem, que erra em 21% dos casos; e um teste A/B com alunos para medir o que interessa — se a questão publicada no ramo certo ajuda mais do que a ausência de resposta.

Fase 1 e Fase 2 lado a lado. A Fase 1 respondia com modelo de linguagem e media concordância com outro modelo; a Fase 2 decide por regra e mede contra rótulo humano.

Dimensão	Fase 1	Fase 2
Quem decide	LLM + verificador	busca lexical + logística
Custo por mil questões	chamada de API	R$ 0
Determinismo	não (amostragem do modelo)	sim (saída reprodutível)
Amostra de avaliação	359 questões, 2 rotuladores de IA	100 questões, rótulo humano
Publicadas	222/359 (61,8%)	115/659 (17,4%)
Qualidade medida	concordância 0,90–0,92 com IA	0,95 (19/20) contra gabarito

Quando eu não usaria este sistema. Em três situações. Primeira, se a avaliação for pelo tema exato: o sistema entrega o ramo, e a leitura estrita cai para 0,50. Segunda, se houver exigência de cobertura alta: publicar 17% não serve para quem precisa responder 83% das questões — nesse caso é melhor aceitar menos precisão e usar a confiança só como ordenação da fila. Terceira, se o catálogo mudar toda semana: cada mudança de tema exige reenriquecer o objeto correspondente, e o custo de manutenção deixa de ser desprezível.

O que eu levaria da Fase 1. Duas coisas sobreviveram à troca de arquitetura: o dicionário jurídico curado à mão e a régua de aceitação (pai e filho contam, irmão não). A primeira alimenta a expansão de consulta; a segunda define o que é acerto. O resto — prompt, verificador, cache de contexto — não tem lugar num pipeline determinístico, e essa é a lição da fase.

O que eu mediria no primeiro mês em produção. Quatro números, todos baratos: (i) taxa de aceitação da sugestão publicada, na amostra revisada por humano; (ii) tempo médio de revisão por questão; (iii) proporção de revisões que mudam o tema sugerido; (iv) taxa de questões fora da taxonomia. Os dois primeiros medem custo, os dois últimos medem se o catálogo e o limiar estão calibrados. Nenhum deles exige novo modelo — só registro do que o revisor fez.

REPRODUTIBILIDADE

`./scripts/regenerar.sh`	pipeline completo: CSV + TXT + artefatos
`python -m src.decisao`	só a decisão (115 publicar / 544 revisar)
`python -m src.previsao`	só a previsão (0,91 [0,76–0,99])
`python -m src.auditoria`	manifesto com hashes de todos os insumos

Sem rede e sem LLM. 60 s em um núcleo; sha256 do `enriquecimento_v01.jsonl` = `7bbda02e4c658484`. O `publicacao.csv` sai idêntico em duas execuções seguidas (mesmo hash).

O que eu não entreguei. Não entreguei um classificador de *fora* (8 exemplos não sustentam), nem cobertura acima de 17%, nem prova de 95%. Entreguei o que a amostra sustenta, com o intervalo e a régua explícitos — e o caminho barato para subir: rótulos humanos, começando pelos casos de desacordo.

(D) MEMO PARA O PROFESSOR

Este memo é para você, especialista em Direito, não em IA.

O que eu fiz

- Montei um sistema que decide, para cada uma das 659 questões, se publica o tema ou manda para revisão. Publiquei 115 (17,4%) e mandei 544 para revisão.
- Nenhuma decisão é tomada por modelo de linguagem em tempo de execução. O sistema compara o texto da questão com o texto dos temas, promove o subtema ao tema principal e só publica quando os quatro métodos de busca concordam e a confiança passa de um limiar.

Por que a taxa de publicação é baixa

- Porque a meta é 95% de acerto. Com 100 questões rotuladas, cada acerto vale 1 ponto: para *provar* 95% eu precisaria de 60 publicações sem nenhum erro. Preferi publicar menos e dizer com honestidade o que a amostra sustenta.
- O que a amostra sustenta: 19 acertos em 20 publicadas. Quando o limiar é escolhido sem olhar o grupo que está sendo medido, 13 em 17 (0,76). A previsão para o restante é 0,91 [0,76–0,99]; o 0,76 é o piso conservador, e o intervalo cobre os dois.

O que mudou nesta fase

- Tiramos o modelo de linguagem da decisão. O sistema é determinístico: a mesma entrada dá a mesma saída, e o resultado é auditável linha por linha.
- Enriqueci os 351 temas com sinônimos, nomes técnicos e uma definição curta. Isso subiu o acerto do *ramo* de 0,63 para 0,74 — e ramo é o que o sistema publica.
- Legislação Especial perdeu as 5 publicações que dependiam do `lei_match`; resta 1 (0 na folha), e a diferença entre antigas e novas é 0,15 contra 0,18.

O que eu preciso de você

- **Rótulos:** 200 a 300 questões classificadas por você (ou por um monitor) mudam o patamar. É o único caminho para provar 95% em vez de estimar.
- **Leitura da régua:** se a avaliação for pelo tema exato e não pelo ramo, o resultado cai de 0,95 para 0,50 — e aí a conversa é outra. Vale confirmar qual leitura vale.

O que eu não afirmo

- Não afirmo 95% de precisão: afirmo 0,91 [0,76–0,99] e explico por que o intervalo é largo.
- Não afirmo que o sistema acerta o subtema: ele acerta o ramo. Publicar o ramo é uma escolha compatível com a régua, não um acidente.
- Não afirmo estabilidade: mudar o vocabulário dos temas muda o ramo de 40% das questões, e uma correção de catálogo em três nós mudou 18 decisões. É a limitação mais séria e está no relatório, não na nota de rodapé.