Classificação de tópicos: case VDE

Fase 2: um sistema que decide sem modelo de linguagem

Leo Vitor

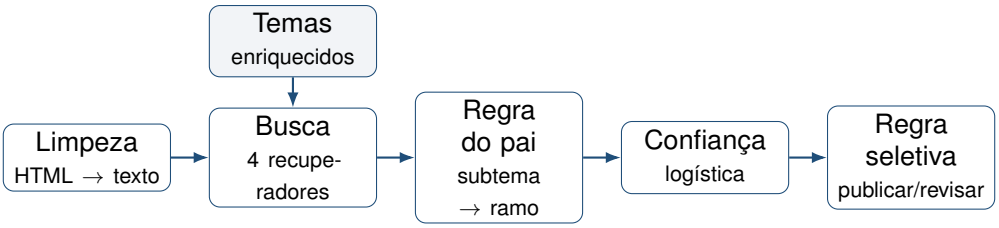
Sumário executivo

- **Resultado:** publiquei 115 das 659 questões (17,4%) e mandei 544 para revisão. Nas 559 questões fora da folha-verdade, a cobertura é 94/559 (0,17).
- **Previsão de precisão: 0,76 (0,53 a 0,90).** É a estimativa aninhada (13 acertos em 17), em que o limiar é escolhido sem ver o grupo medido. Na regra fixa, medida nos mesmos 100 rótulos, foram 19 em 20 (0,95): esse número é o teto otimista, não a previsão.
- **A meta de 95% não é demonstrável com 100 rótulos.** Pela cota unilateral de 95% (Clopper-Pearson), seriam precisas umas 60 publicações auditadas sem nenhum erro; o sistema publica 20.
- **Nenhum modelo de linguagem na decisão.** Um comando regenera a entrega em cerca de um minuto, sem rede. O único insumo gerado por LLM é o arquivo de temas enriquecidos, versionado por hash.

17,4%	0,76	0,74	R$ 0
COBERTURA (115/659)	PRECISÃO PREVISTA	RAMO CERTO NO TOP-1	CUSTO POR QUESTÃO

a) O sistema

O sistema responde três perguntas, sempre na mesma ordem: qual é o tema mais provável, em que ramo da árvore ele está e se vale publicar. Nenhuma das três chama modelo de linguagem.



1. **Temas enriquecidos.** Os 351 temas ativos ganharam sinônimos, institutos e uma definição curta, gerados por LLM uma única vez, revisados e congelados num arquivo versionado. Um validador confere campos, leis citadas e colisões entre pai e filho. É a peça que mais rendeu (tabela abaixo), e é exatamente o uso de LLM que o case permite.
2. **Busca com quatro recuperadores.** TF-IDF por palavra, TF-IDF por caractere, BM25 e a fusão deles (RRF). A fusão é a que ranqueia; os quatro juntos servem para medir consenso.
3. **Regra do pai.** Se o mais provável é um subtema, publico o tema pai. Pela régua, o pai vale para o subtema certo e para todos os irmãos, então a regra nunca transforma um acerto em erro. Na folha, ela eliminou os erros entre irmãos: nenhum dos erros restantes é desse tipo.
4. **Confiança.** Uma regressão logística sobre 13 sinais do topo do ranking (margens, consenso entre recuperadores, nível do tema, disciplina de origem, tamanho do tema na origem e score do primeiro), treinada fora da dobra nos 100 rótulos.
5. **Regra seletiva.** Publica só se pelo menos três dos quatro recuperadores concordarem e a confiança passar de 0,896. O resto vai para revisão, com a sugestão do sistema.

Texto usado para cada tema (92 questões com tema)	Ramo certo no top-1	Diferença
Caminho e título (base)	0,630	
Base e títulos dos filhos	0,630	0,000
Base e termos do dicionário jurídico	0,620	−0,011
Só sinônimos	0,609	−0,022
Enriquecido (sinônimos, institutos e definição)	**0,739**	**+0,109**

O critério de entrada foi escrito antes do teste (ganho de pelo menos 0,05). O intervalo pareado do ganho é de 0,033 a 0,196: positivo, mas não folgado. Nenhum campo isolado basta; o ganho vem da combinação.

O que testei e descartei. Cada ideia entrava só com ganho medido no ramo certo no top-1.

- **Embeddings densos** (multilingual-e5-large), mesmo com os temas enriquecidos: 0,53 a 0,68 sozinhos; a melhor fusão ganhou uma questão, com intervalo cruzando zero. Distinções jurídicas são lexicais (um número de lei, um termo técnico), e o embedding as aproxima.
- **Vizinhos entre questões (kNN):** só 41 dos 109 ramos aparecem na folha, então o teto é baixo (0,79 com acerto perfeito) e o resultado ficou em 0,43 a 0,48.
- **Reranker de candidatos** (16 sinais): empatou ou perdeu. **Cascata em dois estágios**: dá a mesma decisão da regra do pai. **Disciplina de origem como prior**: duas questões a mais em 92, dentro do ruído.
- **O sinal de lei citada**, que entrou e saiu. Tinha 1 caso positivo em 100 e dominava a confiança. Removê-lo custou 5 das 6 publicações de Legislação Especial e derrubou a precisão aninhada de 0,87 para 0,76. Preferi um número pior a um sistema apoiado num caso.

b) Os 100 rótulos

Como usei. Os 100 rótulos tiveram três papéis, sempre separados: escolher peças do sistema (com o critério escrito antes), treinar a confiança e medir a precisão. Para não medir no que treinei, usei 5 dobras repetidas 5 vezes, estratificadas por disciplina e com questões quase iguais sempre na mesma dobra (não houve nenhuma). O limiar de publicação é escolhido dentro de cada dobra e aplicado na parte que ficou de fora. Ao auditar esse protocolo, achei um vazamento: o limiar era escolhido com probabilidades que já tinham visto o grupo de teste. Corrigido, as publicações aninhadas caíram de 33 para 17. O número que entrego é o corrigido.

Leitura (pela régua do case)	Publicadas	Acertos	Precisão (IC 95% Wilson)
Regra fixa, in-sample (mesmos 100)	20	19	0,95 (0,76 a 0,99)
Aninhada, limiar escolhido fora do grupo	**17**	**13**	**0,76 (0,53 a 0,90)**
Publicando tudo	100	68	0,68

O que os rótulos mostraram sobre a convenção da equipe.

- **Gêmeos.** Oito temas aparecem duas vezes, com o mesmo título, em disciplinas diferentes. Nas 6 questões da folha com tema gêmeo, a equipe usou o de Legislação Especial em 5; na Q0324 marcou os dois (um como central, outro como extra). E não seguiu a disciplina de origem: a Q0091 veio como Direito Penal e foi para Lei de Execução Penal (Legislação Especial). Na fase 1, quando o gêmeo não batia com a disciplina de origem, eu mandava a questão para revisão; os rótulos mostram que essa regra teria barrado um acerto (Q0091). São só 6 casos.
- **Nível e extras.** A equipe rotula no tema em 53 das 92 questões e no subtema em 39, e usa extras em 39: questões multitemáticas são comuns, e os extras dão mais de um jeito de acertar pela régua.
- **Fora da árvore:** 8 das 100, sem nenhum traço comum que permita detectá-las.
- **A régua pesa.** A mesma predição acerta 0,95 in-sample pela régua do case, 0,90 se só o ramo contasse e 0,50 se fosse exigido o tema exato. O sistema acerta o ramo, não o subtema.

c) Diagnóstico

O que atrapalha nos dados e nos temas. Os gêmeos, que a régua não deixa trocar. As lixeiras, temas que concentram centenas de questões na origem. O assunto de origem, que também é uma lixeira ("Concurso de Crimes" rotula 43 questões de temas variados). A sobreposição entre a lei especial e o instituto correspondente do Código. E um erro de catálogo: pela Lei 14.197/2021, os temas 5148 e 5156 são capítulos do tema 5155. Corrigi isso no entregável, sem trocar IDs. É uma correção legal, não um ajuste de métrica: nenhuma publicação cai nesses temas, mas a mudança de texto deslocou 18 decisões, com 15 publicações perdidas, 3 ganhas e saldo de -12. A avaliação de precisão continua sendo feita contra a árvore original; por isso declaro o custo e levo a correção ao professor para confirmação.

Onde o sistema perde. Nas 92 questões com tema: 20 publicadas certas, 1 publicada errada, 48 em revisão com o ramo certo já em primeiro (18 passariam com um limiar mais baixo; 30 precisam de uma confiança melhor), 18 com o ramo certo entre o 2º e o 10º lugar e 5 fora do top-10. A busca não é mais o gargalo principal: a confiança é.

Que questões o sistema ainda erra, e o que resolveria cada uma.

Tipo de questão	O que acontece	O que resolveria
Lei de Execução Penal	vai para Teoria da Pena (3 casos); o texto fala de remição ou falta grave, sem citar a lei	descrição do tema 4703 com o vocabulário da execução
Juizado Especial Criminal	vai para procedimento ou ação penal (3 casos), apesar de citar a Lei 9.099	usar a lei citada como evidência, a testar com rótulos novos
Gabarito em subtema	erra o ramo em 36%, contra 19% quando o gabarito é tema	mais rótulos de subtema
Erro confiante	a Q0202 foi publicada errada com confiança 0,97: os quatro recuperadores leem o mesmo texto e erram juntos	um sinal que não venha da busca, validado em rótulos novos
Fora da árvore	8 casos sem traço comum	revisão humana; criar os temas que faltam

Legislação Especial concentra o problema: erra o ramo em 6 de 12 questões, contra 10% em Criminologia. A regra da lei citada não entrou na entrega porque foi desenhada depois de ver os erros e tem poucos casos; fica como o primeiro teste da próxima rodada.

d) Produção: 50 mil questões por semana

Custo e tempo. Classificar as 659 questões leva cerca de 40 segundos num núcleo; 50 mil levam perto de uma hora, sem GPU e sem API. O LLM só volta quando o catálogo muda, para enriquecer os temas novos ou alterados, uma vez por tema. O custo que não escala é a fila: com 17% de publicação, uns 41 mil itens por semana iriam para revisão. Por isso a fila deve ser ordenada pela confiança, com as questões mais perto do limiar primeiro, porque são as que mais mudam de decisão com um rótulo.

Como a correção do professor vira dado de treino. Cada revisão gera uma linha: questão, tema sugerido, tema final e se a sugestão estava certa. Essa linha serve a quatro coisas:

1. é o rótulo "certo ou errado" que o modelo de confiança aprende, que é o gargalo atual;
2. amplia a folha-verdade, que recalibra o limiar e mede a precisão;
3. mostra quais temas acumulam correções, e esses são reenriquecidos;
4. com alguns milhares de linhas, permite treinar um classificador direto sobre o texto.

De quanto em quanto tempo o sistema se retreina.

Peça	Quando	Condição para entrar em produção
Modelo de confiança	toda semana, com as revisões novas	não piorar no protocolo aninhado
Limiar de publicação	a cada uns 100 rótulos novos	precisão aninhada de pelo menos 95%
Temas enriquecidos	quando o catálogo muda	passar no validador; hash novo
Classificador de texto	quando houver uns milhares de rótulos	superar a busca no aninhado

Os volumes (100 rótulos, alguns milhares) são estimativas minhas, a confirmar com o uso.

Como medir a qualidade. Toda semana: a precisão numa amostra de publicadas auditada pelo professor, a taxa de sugestões corrigidas na fila e os reportes de alunos por tema. Para afirmar 95% com segurança pela cota unilateral, a amostra auditada precisa ser de 60 publicações sem erro, não de poucas unidades.

O que eu faria com mais tempo. Em ordem de retorno: (1) rótulos priorizados, primeiro nas questões que citam lei, em Legislação Especial e perto do limiar; (2) a regra da lei citada, testada com rótulos novos; (3) o vocabulário da execução no tema 4703; (4) um sinal de confiança independente da busca, a validar com rótulos novos (o assunto de origem é um candidato, mas hoje é ruidoso); (5) exemplos por tema propostos por LLM e revisados, para cobrir os 68 ramos ausentes da folha.

e) Memo para o professor

Para você, especialista em Direito. Sem jargão de IA.

O que eu construí

- Um sistema que decide, para cada uma das 659 questões, se publica o tema ou manda para a sua revisão. Ele compara o texto da questão com a descrição dos temas e não usa inteligência artificial na hora de decidir. Publiquei 115 (17%) e mandei 544 para você.
- Espero que umas 3 de cada 4 publicadas estejam certas. Não consigo prometer os 95% pedidos: com 100 questões rotuladas, não há como provar isso.

O que encontrei

- O sistema quase sempre acerta o assunto geral; quando erra, confunde temas vizinhos. Ele publica no tema principal, não no subtema, porque a régua aceita isso e é mais seguro.
- A maior dificuldade é Legislação Especial: metade das questões vai para o tema correspondente do Código. Questões de execução da pena vão para Teoria da Pena, e questões de Juizado Especial vão para procedimento ou ação penal.
- Quando a questão cita uma lei especial, isso costuma ser uma pista, mas ainda não usei como regra: são poucos casos e a ideia veio depois de eu ver os erros.
- Nos temas com nome repetido em duas disciplinas, a sua equipe usou quase sempre o de Legislação Especial (5 de 6), e não a disciplina de onde a questão veio.

O que recomendo mudar nos temas

- Dar nomes diferentes aos 8 pares de temas repetidos (por exemplo, citar a disciplina no título): 4684/6716, 5063/5466, 4688/6717, 4702/6723, 4704/6724, 4703/6734, 4705/6725 e 4708/6728.
- Deixar mais clara a fronteira entre Lei de Execução Penal e Teoria da Pena, e entre Juizado Especial Criminal e Procedimento Sumaríssimo.
- Confirmar a correção que eu já fiz em “Instituições Democráticas” (5148) e “Funcionamento dos Serviços Essenciais” (5156): pela Lei 14.197/2021, são capítulos de “Estado Democrático de Direito” (5155), não temas irmãos dele.
- Rever os temas que hoje acumulam centenas de questões sem relação com eles.

O que preciso de você

- Revisar primeiro as questões que eu ordenar na fila: as mais perto da decisão. Cada correção sua ensina o sistema e é o que permite, com o tempo, publicar mais com segurança.
- Rotular de 200 a 300 questões, começando pelas que citam lei e pelas de Legislação Especial. No ritmo atual, isso dá umas 35 a 50 publicadas para calibrar; não prova 95%. Para provar, seria preciso auditar 60 publicadas sem erro.
- Confirmar qual dos dois nomes é o oficial em cada par de temas repetidos.