Classificação de tópicos: case VDE

Do raciocínio ao desenho de produção

Leo Vitor

Sumário executivo

- Operação: 222 publicadas (61,8% das 359), 136 em revisão, 1 fora do escopo.
- Qualidade: **0,90 a 0,92** contra dois rotuladores de IA, que entre si concordam em 0,85. Os rótulos vêm de IA: mede-se concordância, não precisão.
- Com 60 itens, **não há como separar 90% de 95%**: os intervalos se sobrepõem. A meta de 95% permanece **não demonstrada**.

Nota de calibração: a previsão foi **revisada após a segunda rotulagem**: precisão ∼0,86 (intervalo 0,74 a 0,94) e cobertura ∼0,62. O resultado central (0,90) é concordância com um rotulador de IA, não precisão; o case compara a previsão com o gabarito de especialistas, que aqui não existe.

a) Como eu pensei

O desafio é escolher o tema certo de cada questão entre ∼375 temas parecidos, sem mandar tudo para revisão. O erro nasce em dois pontos, e tratei cada um: (1) o tema certo não está entre as opções oferecidas ao modelo; (2) o modelo escolhe, mas não sabe quando não tem certeza. Daí o desenho de duas etapas: uma busca que garante a lista de opções e um juiz com abstenção, seguido de uma checagem que corrige o segundo ponto.

Uma busca textual propõe candidatos (TF-IDF traz os 10 mais próximos, mais os pais e os filhos dos 3 primeiros). Dois modelos (`gemini-3.6-flash` e `gemini-3.1-flash-lite`) avaliam as opções em quatro votos. Um verificador de 5º voto, com a árvore inteira, entra *antes* da consolidação e empurra para revisão quando discorda. Só então as regras consolidam: votos iguais publicam; votos em subtemas do mesmo ramo publicam no nó comum (a régua aceita pai/filho); ramos diferentes vão para revisão; maioria de `fora` vira `fora`.

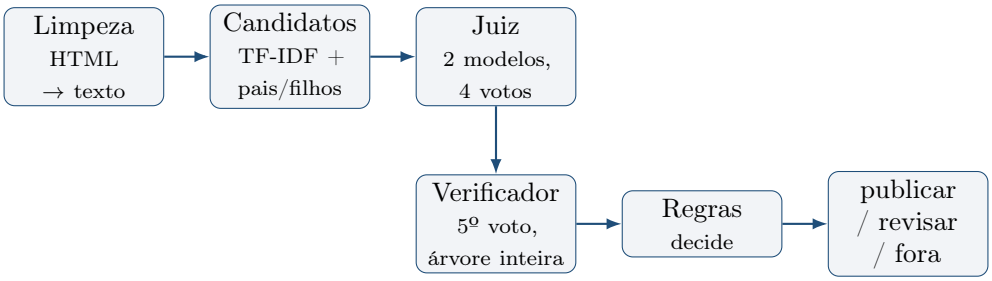


Figura 1: Fluxo do pipeline entregue. O verificador (5º voto, *antes* das regras) vê a árvore inteira e pega o erro "confiante e errado"; não provei que seja a única forma.

Quando há dúvida entre filhos, publicar no pai é aposta de risco assimétrico: sob a régua, o pai é sempre aceito se a verdade for um dos filhos votados. Publicar menos (222 em vez de 261) reduz o risco, mas não comprova 95%.

Onde eu errei, e o que isso mudou. Dos 11 erros publicados na base, 6 são de busca (o tema certo não estava na lista) e 5 de decisão. Todos os 11 foram **votos unânimes**: quando a busca traz as opções erradas, os dois modelos concordam no erro, e a concordância sozinha não sinaliza o problema. Foi por isso que criei o verificador.

O que testei, e o que descartei. *Testado e descartado:* política seletiva (95 questões com base em ∼17 rótulos, na mesma amostra); BM25 e RRF (fusão *lexical*); embeddings densos (`e5-large` local: empataram); subir sempre para o tema pai (+1 caso); SVM linear (0,441). *Descartado por argumento:* cross-encoder, que só reordena a lista e não resolve o tema que não entra nela.

O que fiz com o diagnóstico. Como o erro de busca se concentra em legislação especial, ataquei esse ponto offline, sem tocar na entrega: um dicionário jurídico (traduz a citação da questão para o

termo do título, ex.: "Lei 11.340" → "Lei Maria da Penha") somado à expansão por irmãos. Os resultados estão na Seção b, inclusive um teste fim-a-fim que mostrou um limite importante.

b) Diagnóstico

Números (93 questões rotuladas por IA).

Métrica	Valor
Concordância observada (base, 261 publicadas)	0,838 (57/68)
Concordância observada (após verificador, 222)	**0,90 (54/60)**
Wilson 95% da entrega	[0,80; 0,95]
Erros publicados na base	11 (6 de busca, 5 de decisão)

Publicadas ao longo do trabalho, a cada ajuste de regra: 255, 263, 246, 261 e 222.

Duas ressalvas antes dos números. (1) Os rótulos vêm de outro LLM (DeepSeek), a partir do texto da questão e da lista de temas: o 0,90 é concordância entre modelos, não precisão contra especialistas, que permanece desconhecida. (2) O recall da lista que o juiz *realmente recebeu* na entrega, já com o fallback, foi de 0,882 (82/93): número inflado (parte das questões recebeu a árvore inteira) e *não* comparável ao 0,667 da busca pura.

Como o catálogo atrapalha. (1) Gêmeos: 8 pares de temas com o mesmo título em disciplinas diferentes. A régua conta apenas *um* dos dois como certo, e o pipeline não sabe qual. *O porquê da regra:* publicar no tema errado é o pior erro (o aluno estuda o tópico errado), enquanto revisar só atrasa; na dúvida entre gêmeos, rebaixar é a aposta segura. Na entrega, a regra é *publicar o gêmeo quando a disciplina de origem coincide com a raiz do tema*; caso contrário, rebaixar para revisão. É uma **premissa adotada** (a organização ainda não confirmou a convenção): custa **24 questões rebaixadas** ($\approx$ 6,7 p.p. de cobertura) no entregue. (2) Lixeiras: temas com muitas questões na origem ($\geq$ 40). (3) Sobreposição pai/filho, que a estratégia do nó comum explora a favor.

O que atrapalha nos dados. (1) A `disciplina_origem` coincide com a do tema escolhido em $\sim$95% das publicadas rotuladas (3 discordâncias em 60) e serve de desempate; mas 2% das questões vêm de fora do recorte (Constitucional, Civil, Tributário, Ambiental) ou sem valor. (2) O `assunto_origem` é enganoso: a Q0026 (Lei Maria da Penha) veio como "Ação Penal". (3) Há questões multitemáticas (Q0016, Q0085), em que o "tema certo" é uma escolha, não um fato.

Bloqueio por conteúdo sensível. Uma questão (Q0227, cenários de violência sexual em Direito Penal, com `assunto_origem` "Lesão Corporal", enganoso) teve a resposta bloqueada pelo filtro de segurança do modelo. O pipeline trata isso como abstenção: vai para revisão com o motivo registrado e não repete a chamada. Em produção, porém, um filtro sem critério jurídico decide o que cai na fila humana; a recomendação é *contar* esses casos e avaliar se dá para ajustar o filtro sem risco, o que só um conjunto de especialistas permitiria checar. (Um caso em 359 daria $\sim$140 por 50 mil, mas é extrapolação ingênua: o recorte é só de Penal.)

Onde o erro se concentra. Dos 11 erros publicados, **3 são de legislação especial**; os demais são de Parte Geral, Processo Penal e casos de ambiguidade real. Onde o erro de *busca* aparece, o juiz escolhe, de forma unânime, o vizinho mais próximo.

O verificador funciona? Fixei o critério *antes* de rodar: vetar ao menos 3 erros reais, com no máximo 20% de vetos falsos. Ele vetou **5 dos 11 erros** publicados (4 de busca, em que o tema certo nem fora oferecido) e recusou **3 das 57 certas** (5%), dentro do critério. Dos 6 erros que escaparam, minha adjudicação (não especialista, em `docs/adjudicacao_erros.csv`) diz que 1 favorece o rótulo (Q0120), 1 favorece o modelo (Q0238) e 4 são ambíguos (Q0273, Q0016, Q0306, Q0085). É leitura de um revisor, não medição.

Reconciliação do gargalo. A busca limita a **precisão das publicadas** (tema certo fora da lista); agregação, gêmeos e limiar limitam a **cobertura**. Melhorar só a busca ataca o primeiro limite, não o segundo (o A/B mostra).

Ataque ao ponto fraco. Duas alavancas de busca, testadas offline (93 questões, $k = 10$):

Mecanismo de busca	`recall_hier`	Legislação Especial
Busca pura (TF-IDF + pais/filhos)	0,667	5/19
+ dicionário (`top+dic`)	0,731	12/19
+ irmãos, sem dicionário (`irmao`)	0,882	9/19
dicionário + irmãos	**0,957**	**16/19**

O dicionário sobe o piso; os irmãos, o topo. No holdout a melhora se mantém (0,613 → 0,968), *com a ressalva* de que a última expansão do dicionário foi decidida olhando os erros remanescentes, um deles no holdout; não é um holdout estritamente cego.

Teste fim-a-fim (A/B pago, nível da decisão)

Levei o dicionário até a decisão na Opus (150 questões, 148 com tema; quase fora da amostra, 41 já no conjunto de desenho), mesmos modelos e regras, com o verificador:

Configuração (limpa)	`recall_hier`	Publicação correta (c/ verificador)
`filho` (controle)	0,791	0,886 (78/88)
`filho+dic` (dicionário)	0,845	0,888 (79/89)

O dicionário sobe o recall (+5,4 p.p.) mas muda a decisão em +0,2 p.p. (1 questão). A maior parte dos acertos extras cai em `revisar`: o juiz acha o tema, mas a agregação não publica, e a métrica conta só as publicadas. No pareado: +2 conserta, −1 quebra, 8 neutras. Não foi adotado na entrega.

Duas rotulagens, lado a lado. A concordância do pipeline é medida contra dois rotuladores de IA; nenhum é o gabarito de especialistas, e os dois não são independentes entre si (41 questões em comum):

Rotulagem	Itens	Concordância	Wilson 95%
DeepSeek (conjunto de desenho das regras)	60	0,90	0,80 a 0,95
Opus (checagem quase fora da amostra)	88	0,92	0,84 a 0,96
Entre os dois rotuladores (régua pai/filho)	41	0,85	0,72 a 0,93

O resultado central (0,90) vem do conjunto que orientou o desenho das regras; a checagem com a Opus (0,92) repete 41 dessas questões, então é *quase* fora da amostra. O achado central: as duas rotulagens concordam no ramo, não no tema exato (0,54 no exato e 0,85 na régua pai/filho nas 41 comuns). Cuidado com os dois "88": o **81/88** é o pipeline entregue na Opus; o **78/88** é o braço `filho` do A/B acima, uma configuração diferente, não o mesmo conjunto.

Quanto custa precisar mais. Como 95% é a pergunta central, medi o trade-off entre cobertura e precisão (varredura de limiar no conjunto de validação). Os intervalos de Wilson abaixo mostram por que *não* dá para cravar 95%:

Cobertura	Precisão observada	n	Wilson 95%
0,73	0,84	32	[0,68; 0,93]
0,62	0,90 (entrega, c/ verificador)	60	[0,80; 0,95]
0,59	0,86	28	[0,69; 0,94]
0,43	0,93	15	[0,70; 0,99]
0,26	1,00	6	[0,61; 1,00]

c) Produção (50 mil questões por semana)

Esta seção é proposta; não foi executada nesta entrega (orçamento limitado de API e prazo curto).

Encaixe no fluxo. (1) as questões novas entram pelo importador; (2) a busca propõe candidatos; (3) um classificador leve resolve a maioria dos casos com probabilidade calibrada; (4) o LLM julga o que

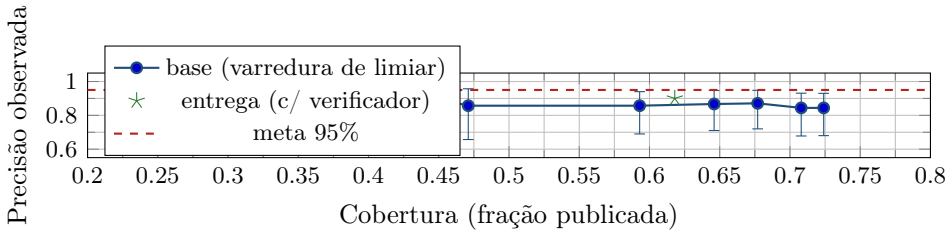


Figura 2: Cobertura × precisão, com intervalos de Wilson. Os intervalos se sobrepõem: com esta amostra não dá para separar 90% de 95%. A cobertura alta só aparece com $n \leq 15$ e intervalo largo.

sobra e um verificador checa os ambíguos; (5) o que ainda diverge vai para a fila de revisão humana; (6) os reportes de alunos e a revisão alimentam a amostra auditada que mede a qualidade semana a semana.

Arquitetura, do barato para o caro. (1) Recuperação ampliada: TF-IDF + dicionário jurídico e irmãos (grátis); embeddings jurídicos densos só com GPU. (2) Classificador treinado: *só depois de acumular rótulos dos professores* (hoje não existe; o SVM deu 0,441). (3) LLM com verificação seletiva e revisão humana nas divergências.

Custo por etapa. Medido onde há registro (fallback e verificador), estimado no juiz (juiz base ≈ 1,5 mil tok/chamada; verificador, 8,7 mil na rodada real):

Etapa (359 questões)	Tokens de entrada	Custo (US$, preços reais)
Juiz (4 votos)	∼2,1 M	∼1,04
Fallback (28 questões × 4)	∼0,9 M (medido)	∼0,47
Verificador (246 chamadas)	2,14 M + 18 mil saída (medido)	∼0,56
Total	**∼5,2 M**	**∼2,1**

Preços: `gemini-3.6-flash` (0,75 / 3,75 por milhão) e `gemini-3.1-flash-lite` (0,25 / 1,50). **∼14,4 M tokens de entrada por 1.000 questões** (não os 33,8 M que supunham a árvore inteira em toda questão). O verificador tem *mais* tokens por chamada, mas custa *menos* por questão que os quatro votos do juiz, porque usa só o modelo barato. É um **piso**, só tokens de entrada (sem raciocínio nem experimentos): a primeira rodada completa consumiu ∼R$ 14 no painel, mais que o US$ 1,04 do juiz na tabela. Custo por questão ∼US$ 0,0058: ∼US$ 5,8 por mil, ∼US$ 290 por semana para 50 mil.

Cache de contexto. O bloco repetido (instruções + árvore, ∼9 mil tokens) pode ser enviado uma vez e reaproveitado. O plano em tokens é grátis (`-dry-run`: ∼72% de economia na entrada); o teste real é *pequeno*, a **saída não foi guardada** e os créditos de API acabaram, então não o reexecutei. Reproduzir com `python -m src.contexto_cache -criar` (`docs/cache_contexto.md`); o desconto real em R$ só se confirma no contrato.

Limitações honestas. (1) Juiz e verificador são da mesma família (Gemini): erram juntos, e a Q0120 passou pelos dois. (2) O `THRESH` e as lixeiras quase não filtram (confianças perto de 0,95; nas lixeiras o erro foi *menor*, 0,12 contra 0,21). (3) As regras (verificador, gêmeos) foram desenhadas na amostra de 60 em que são medidas. (4) A verificação encarece com a árvore inteira por chamada.

Medição contínua. Três métricas semanais, além do tamanho da amostra: (i) precisão na amostra auditada; (ii) taxa de correção da fila (quantos revisados estavam errados); (iii) reportes de alunos por tema, como sinal de erro que a auditoria não pegou. Para separar de fato 90% de 95% são necessários **∼434 itens por grupo** (poder 80%); para ±5 p.p. em torno de 0,90, ∼139 itens. A amostra auditada precisa ser da ordem de **centenas de itens**, não de dezenas.

O que eu faria com mais tempo. (1) Um verificador de *outra família* (hoje juiz e verificador são ambos Gemini e podem errar juntos); (2) rótulos de especialistas nos 20 a 30 desacordos; (3) a expansão por irmãos limitada aos casos de baixo risco; (4) o cache de contexto em produção; (5) confirmar a convenção dos gêmeos.

Meta de 95%. Sem gabarito humano, não há garantia formal. A entrega prioriza precisão e uma avaliação honesta; não afirmamos que os 95% foram atingidos.

(d) Memo para o professor

Este memo é para você, especialista em Direito, não em IA. Uma página, sem jargão.

O que eu construí

- Um sistema que decide, para cada uma das 359 questões, entre publicar, revisar ou fora.
- Resultado: 222 publicadas (61,8%), 136 em revisão e 1 fora do escopo.
- 0,90 a 0,92 de concordância contra duas avaliações feitas por IA (que entre si concordam em 0,85), mas nenhuma é o gabarito humano: a meta de 95% não está confirmada.

O que encontrei

- Dos 11 erros publicados, só 3 são de legislação especial; alguns vêm de questões com assertivas I–IV, em que o enunciado dá pouca pista e o tema certo nem chega a ser oferecido ao modelo. É um problema de busca, não de conhecimento jurídico.
- O erro é confiante: nos casos errados, os dois modelos concordaram por unanimidade. Por isso adicionei a verificação, um 5º julgamento que vê todos os temas e manda para revisão quando discorda.
- O catálogo tem armadilhas: temas com o mesmo nome em disciplinas diferentes e temas que se sobrepõem (pai e filho dizendo o mesmo). *Não observei* erro por escolha de gêmeo, mas são poucos casos e a convenção ainda não foi confirmada.

O que já melhorei (offline, sem tocar na entrega)

- Um dicionário jurídico somado à busca por temas irmãos elevou o achado do tema (ou de um relacionado) de 0,667 para 0,957; em legislação especial, de 5/19 para 16/19. A parte local é grátis.
- Testei isso até o fim: o ganho de busca não se converteu em publicação (+0,2 ponto percentual, 1 questão). Por isso não mudei a entrega.

O que recomendo mudar nos temas

- Dar nomes que distingam os gêmeos (ex.: citar a disciplina no título). São 8 pares, com ids: 4684/6716, 5063/5466, 4688/6717, 4702/6723, 4704/6724, 4703/6734, 4705/6725, 4708/6728.
- Fundir ou hierarquizar melhor subtemas que repetem o conteúdo do pai.
- Marcar temas "guarda-chuva" (onde aceitar o nível geral é seguro) e os que exigem o nível específico.

O que preciso de você

- Uma amostra rotulada por você, começando por **20 a 30 casos de desacordo** entre as duas avaliações de IA, para medir a precisão de verdade. Hoje a referência é assistida por IA e só mede concordância.
- Confirmação da convenção dos temas gêmeos no gabarito.
- Um parecer sobre 6 casos em que o modelo e o rótulo de IA discordam (primeiro o que o modelo publicou, depois o que o rótulo sugere):
  - Q0120 (provas; resposta à acusação): Teoria Geral das Provas × Defesa Preliminar.
  - Q0238 (reforço da fiança, CPP): Liberdade Provisória × Prisão em Flagrante.
  - Q0273 (crime punido na modalidade culposa): Crime Doloso e Culposo × Condescendência Criminosa.
  - Q0016 (jurisprudência sobre prisão): Teoria Geral das Prisões × Prisão Preventiva.
  - Q0306 (associação criminosa): Crimes Contra à Paz Pública × Organizações Criminosas.
  - Q0085 (concussão, agente funcionário público): Concurso de Pessoas × Concussão e Excesso de Exação.