Classificação de tópicos: case VDE

Do raciocínio ao desenho de produção

Leo Vitor

Sumário executivo

- **Resultado:** publiquei 222 das 359 questões (61,8%), mandei 136 para revisão e deixei uma fora do escopo.
- **Qualidade:** o sistema concorda de 0,90 a 0,92 com dois rotuladores de IA, que entre si concordam em 0,85. Isso mede concordância com um rotulador, não precisão.
- Com uma amostra deste tamanho não separo 90% de 95%, e por isso não afirmo a meta.

Minha previsão final é 0,86 (de 0,74 a 0,94), com cobertura de 0,62. Baixei de 0,90 porque o número antigo vinha de um único rotulador de IA; com uma segunda avaliação independente, ele parecia otimista.

a) Como eu pensei

Comecei pelo caminho mais simples: pedir a um modelo que escolhesse o tema de cada questão entre os temas que uma busca por palavras trazia. As primeiras rodadas mostraram dois problemas diferentes. Em várias questões o tema certo nem estava entre os candidatos, e o modelo escolhia o vizinho mais parecido com toda a confiança. Quando pus dois modelos para votar, eles concordavam justamente nesses erros, de modo que a votação, que eu esperava que servisse de alarme, não avisava de nada.

O desenho final tem três partes. A busca por palavras propõe os temas mais parecidos, mais os pais e os filhos dos mais bem colocados. Dois modelos Gemini (`gemini-3.6-flash` e `gemini-3.1-flash-lite`) votam duas vezes cada, num total de quatro votos. Um verificador, que enxerga a árvore inteira de temas, dá um quinto voto e manda a questão para revisão quando discorda. Só então as regras consolidam: votos iguais publicam; votos em subtemas do mesmo ramo publicam no tema pai (a régua do case aceita pai e filho); temas diferentes vão para revisão; e a maioria de `fora` vira `fora`.

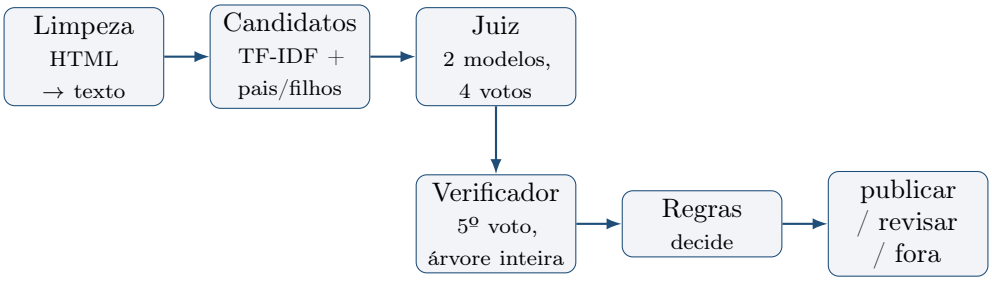


Figura 1: Fluxo do pipeline entregue. O verificador entra antes das regras e vê a árvore inteira.

Dos onze erros que achei entre as publicadas da primeira versão, seis eram de busca (o tema certo não estava entre os candidatos) e cinco de decisão (estava, e o juiz escolheu outro). O que me chamou a atenção foi que todos eram votos unânimes: a votação nunca desconfiou. Foi isso que me levou ao verificador, um quinto voto que enxerga a árvore inteira e manda a questão para revisão quando discorda.

Antes de rodá-lo, escrevi o critério de sucesso: vetar pelo menos três erros reais e recusar no máximo um quinto das questões certas. Ele vetou cinco dos onze erros e recusou três das questões certas, dentro do critério. Dos seis que escaparam, minha leitura é que dois dividem opinião (um a favor do rótulo de IA, um a favor do modelo) e quatro são ambíguos, todos registrados em `docs/adjudicacao_erros.csv`. É a leitura de um revisor, não de um especialista.

O caminho até aqui não foi reto, e descartei várias ideias. A primeira foi uma política que publicava só os casos mais confiáveis: chegou a 95 questões com 100% de concordância, mas eu a abandonei

porque se apoiava em 17 rótulos da mesma amostra que a calibrou. Buscas alternativas (BM25, fusão de rankings e embeddings densos) não superaram a busca simples por palavras. Subir sempre para o tema pai resolveu um caso só, porque o erro raramente era entre irmãos. E descartei o cross-encoder sem testar, porque ele só reordena a lista, e o problema é o tema que não entra nela.

O que funcionou melhor foi atacar a busca offline, sem gastar API. Um dicionário jurídico (que traduz uma citação de lei, como "Lei 11.340", para o nome que aparece no título do tema, "Lei Maria da Penha"), somado à busca por temas irmãos, subiu a taxa com que a busca acha o tema certo ou um parente direto de 0,67 para 0,96. Esse teste não foi totalmente cego, porque ampliei o dicionário olhando os erros que sobraram. Quando levei o dicionário até a decisão final, numa segunda rotulagem independente, o ganho quase desapareceu: a busca foi de 0,79 para 0,85, mas a concordância das publicadas mudou menos de meio ponto percentual. Os acertos extras caíam em revisão, porque o juiz achava o tema e a agregação não publicava. Por isso, e porque mudar a lista de candidatos invalidaria o cache das chamadas, não adotei a mudança na entrega.

b) Diagnóstico

Os problemas que mais atrapalham vêm do catálogo e dos dados, mais do que do modelo.

Temas gêmeos. O catálogo tem oito pares de temas com o mesmo título em disciplinas diferentes, por exemplo Lei Maria da Penha em Legislação Especial e em Penal. A régua do case aceita só um dos dois como certo, e eu não sei qual; perguntei à organização, que respondeu que a decisão faz parte do case. Adotei então uma premissa conservadora: publico o gêmeo só quando a disciplina de origem da questão coincide com a raiz do tema, e mando o resto para revisão. O motivo é que publicar no tema errado é o erro mais caro (o aluno estudaria o tópico errado), enquanto revisar só atrasa. A premissa custa 24 questões, cerca de 6,7 pontos percentuais de cobertura, e deixa de valer se o professor confirmar qual gêmeo é o oficial.

Dados. Três coisas confundem tanto a máquina quanto uma pessoa. O assunto de origem engana: a Q0026, sobre Lei Maria da Penha, veio como "Ação Penal". A disciplina de origem é bem mais confiável e coincide com a do tema escolhido em cerca de 95% das publicadas rotuladas, embora parte das questões venha de fora do recorte (Constitucional, Civil, Tributário, Ambiental) ou sem valor. E há questões que cabem em mais de um tema (Q0016 e Q0085, por exemplo), nas quais o "tema certo" é uma escolha, não um fato.

Que questões são difíceis. Vi três perfis: assertivas I a IV com pouca pista no enunciado; legislação especial, em que o texto da questão não repete o título do tema; e as que cabem em dois temas. O erro não se concentrou num ramo: dos onze erros da primeira versão, três eram de legislação especial e o resto se espalhava por Parte Geral, Processo Penal e ambiguidade. As lixeiras (temas com muitas questões na origem) pareciam um risco, mas nessas o erro foi menor do que nos demais temas, então a regra extra de confiança que criei para elas quase não filtra nada.

Bloqueio por conteúdo sensível. Uma questão (a Q0227, com cenários de violência sexual) teve a resposta bloqueada pelo filtro de segurança do modelo. O pipeline trata isso como abstenção: a questão vai para revisão com o motivo registrado, e a chamada não se repete. Em produção, isso significa que um filtro sem critério jurídico decide o que cai na fila humana, e esse tipo de bloqueio pode não ser ajustável. Eu recomendaria contar esses casos e mantê-los na revisão humana, em vez de tentar afrouxar o filtro.

Como medi, e o que a medida vale. Não tenho gabarito, então comparei as decisões com rótulos feitos por IA: primeiro o DeepSeek, sobre as publicadas, e depois o Opus, para ver se o resultado se repetia. Não consigo garantir que o DeepSeek não tenha visto saídas do modelo. A tabela resume o que encontrei.

Comparação	Itens	Resultado
Concordância, aceitando pai e filho		
Antes do verificador (261 publicadas) × DeepSeek	68	0,84 (0,73 a 0,91)
Entrega (222 publicadas) × DeepSeek	60	0,90 (0,80 a 0,95)
Entrega × Opus (quase fora da amostra)	88	0,92 (0,84 a 0,96)
DeepSeek × Opus	41	0,85 (0,72 a 0,93)
no tema exato	41	0,54
Verificador, sobre as 261 publicadas antes dele		
Erros apontados e vetados	11	5
Questões certas recusadas	57	3
Limiar de confiança, para chegar perto de 95% de precisão		
Melhor precisão com cobertura útil	15	0,93 (0,70 a 0,99)
Precisão máxima	6	1,00 (0,61 a 1,00)

Nota: o Opus rotulou 88 questões, 41 em comum com o conjunto que usei para desenhar as regras, por isso o chamo de *quase* fora da amostra.

O achado que mais pesa é a quarta linha: os dois rotuladores concordam em 0,85 quando aceito pai e filho, mas em 0,54 no tema exato. A precisão que consigo medir depende, então, de quem rotula, e a de especialistas pode cair em qualquer ponto dessa faixa. Com amostra deste tamanho, os intervalos de 90% e de 95% se sobrepõem; para separá-los com folga eu precisaria de umas 430 questões por grupo.

Também medi quanto custaria chegar perto de 95%. Subindo o limiar de confiança, eu só alcançava precisão alta com cobertura muito baixa, como mostra a última parte da tabela. Com amostras tão pequenas isso não prova nada, e foi por isso que preferi a entrega com 62% de cobertura, dizendo abertamente que não demonstrei a meta.

c) Produção (50 mil questões por semana)

Esta seção é uma proposta: não a executei, por falta de orçamento de API e de tempo.

Encaixe no fluxo. As questões novas entram pelo importador, e a busca propõe os candidatos. Um classificador leve, treinado com os rótulos que os professores forem acumulando, resolve a maioria dos casos e devolve uma probabilidade calibrada. O que sobra vai para o LLM, e um verificador confere os casos ambíguos. O que ainda divergir vai para a fila de revisão humana, e os reportes de alunos e as revisões alimentam uma amostra auditada que mede a qualidade toda semana.

Do barato para o caro. Primeiro, a busca ampliada (dicionário jurídico e irmãos), que é grátis. Depois, o classificador treinado, que só existe quando houver rótulos de professores: com os rótulos de IA que tenho, um classificador linear acertou o tema entre os dez primeiros em 44% dos casos. Por último, o LLM com verificação seletiva e a revisão humana nas divergências.

Custo. Calculei etapa por etapa. O fallback e o teste do dicionário estão medidos em arquivo; o juiz base eu estimei; e o verificador li no console, porque os tokens não foram gravados em arquivo.

Etapa (359 questões)	Tokens de entrada	Custo (US$, preço de tabela)
Juiz (4 votos)	∼2,1 M	1,04
Fallback (28 questões × 4)	∼0,9 M	0,47
Verificador (246 chamadas)	∼2,14 M	0,56
Total	∼5,2 M	2,1
Projeção para 50 mil por semana	—	US$ 290 a R$ 4,6 mil

Os preços são de tabela, e a conta acima é um piso: só tokens de entrada, cerca de 14 milhões por mil questões. O verificador manda mais tokens por chamada, mas custa menos por questão do que os quatro votos do juiz, porque usa só o modelo barato.

O gasto real foi maior: a fatura do painel ficou em R$ 32,98, contando também os experimentos.

Dividido pelas 359 questões, o teto observado é de R$ 0,09 por questão, contra um piso de US$ 0,006 na tabela.

Cache de contexto. O bloco que se repete em toda chamada (instruções mais a árvore, uns 9 mil tokens) pode ser enviado uma vez e reaproveitado. O cálculo em tokens, que não gasta nada (`--dry-run`), indica cerca de 72% de economia na entrada. O teste real foi pequeno e, como os créditos de API acabaram, não o reexecutei; o comando para reproduzir está em `docs/cache_contexto.md`, e o desconto em reais só se confirma no contrato.

Limitações. Juiz e verificador são da mesma família de modelos (Gemini) e podem errar juntos: a Q0120 passou pelos dois. O limiar de confiança quase não filtra, porque as confianças ficam perto de 0,95. As regras do verificador e dos gêmeos foram desenhadas na mesma amostra de 60 questões em que são medidas. E a verificação encarece a conta, porque envia a árvore inteira em cada chamada. Por fim, tudo o que reporto aqui é concordância com rotuladores de IA, não precisão contra especialistas.

Como mediria a qualidade. Toda semana, com três números: a precisão numa amostra auditada por professores; a taxa de correção da fila (quantas questões revisadas estavam erradas); e os reportes de alunos por tema, que mostram erros que a auditoria não pegou. A amostra precisa ser de centenas de itens, não de dezenas, para que os intervalos separem as metas.

O que eu faria com mais tempo. Cinco coisas: um verificador de outra família de modelos (hoje juiz e verificador são ambos Gemini); rótulos de especialistas para 20 a 30 casos de desacordo; irmãos na busca só nos casos de baixo risco; o cache de contexto em produção; e a confirmação da convenção dos gêmeos. Com o professor no circuito, acrescentaria ligações curadas entre leis e temas e entre gêmeos, uma regra de decisão por custo (quando houver probabilidade calibrada) e aprendizado ativo: a revisão dele gera rótulos que treinam o classificador.

(d) Memo para o professor

Este memo é para você, especialista em Direito, não em IA. Uma página, sem jargão.

O que eu fiz

- Montei um sistema que decide, para cada uma das 359 questões, se publica, manda para revisão ou considera fora do escopo. Publiquei 222 (61,8%), mandei 136 para revisão e 1 ficou fora.
- Comparei com duas avaliações feitas por IA, não por especialistas. O sistema concorda com elas de 0,90 a 0,92, mas isso não prova que acerta 95%.

O que encontrei

- Quando erra, o sistema erra com confiança: nos casos que examinei, os dois modelos concordaram no tema errado. Em geral isso acontece porque o tema certo nem aparece entre as opções que o modelo recebe, e não por falta de conhecimento jurídico. Por isso acrescentei uma segunda checagem, que enxerga todos os temas e manda a questão para você quando discorda.
- O catálogo tem armadilhas: oito temas aparecem duas vezes, com o mesmo nome, em disciplinas diferentes, e há temas que se sobrepõem (pai e filho dizendo quase a mesma coisa). Quando há dúvida entre os nomes iguais, prefiro não publicar. Não vi erro causado por isso, mas foram poucos casos.
- Uma busca melhor (dicionário jurídico e temas irmãos) acha o tema certo, ou um parente direto, em 96% dos casos contra 67%. Esse ganho quase não apareceu nas questões publicadas (uma a mais), então não mudei a entrega.

O que recomendo mudar nos temas

- Dar nomes que distingam os gêmeos (por exemplo, citar a disciplina no título). São oito pares: 4684/6716, 5063/5466, 4688/6717, 4702/6723, 4704/6724, 4703/6734, 4705/6725 e 4708/6728.
- Fundir ou hierarquizar melhor os subtemas que repetem o conteúdo do pai.
- Marcar os temas "guarda-chuva" (onde aceitar o nível geral é seguro) e os que exigem o nível específico.

O que preciso de você

- Confirmar qual dos dois nomes é o oficial em cada um dos oito pares.
- Um parecer sobre seis questões em que o modelo e o rótulo de IA discordam (primeiro o tema que o modelo publicou, depois o que o rótulo sugere):
  - Q0120 (provas; resposta à acusação): Teoria Geral das Provas × Defesa Preliminar.
  - Q0238 (reforço da fiança, CPP): Liberdade Provisória × Prisão em Flagrante.
  - Q0273 (crime punido na modalidade culposa): Crime Doloso e Culposo × Condescendência Criminosa.
  - Q0016 (jurisprudência sobre prisão): Teoria Geral das Prisões × Prisão Preventiva.
  - Q0306 (associação criminosa): Crimes Contra a Paz Pública × Organizações Criminosas.
  - Q0085 (concussão, agente funcionário público): Concurso de Pessoas × Concussão e Excesso de Exação.
- Se puder, rotular de 20 a 30 questões em que as duas avaliações de IA discordam, para medirmos a precisão de verdade.